

KLASIFIKASI KUALITAS TANAH UNTUK JENIS TANAMAN MENGUNAKAN NEURAL NETWORK



KHANSA FITRI ZHAFIRAH	G6401221017
AHMAD FAIQ IZZULHAQ	G6401221036
HAMDAN ARIF DAROJAT	G6401221063
MAYSA FAZILA LUBIS	G6401221068
AMMAR RADHI AZIZ CHAN	G6401221075

**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2024**

DAFTAR ISI

ABSTRAK	3
1. PENDAHULUAN	2
1.1. Latar Belakang	2
1.2. Rumusan Masalah	2
1.3. Tujuan	3
1.4. Manfaat	3
2. TINJAUAN PUSTAKA	4
2.1. Neural Network dalam Pertanian	4
2.2. Parameter Kualitas Tanah	4
2.3. Implementasi Teknologi Kecerdasan Buatan	4
2.4. Tantangan dan Peluang	4
3. METODE	6
3.1. Deskripsi Dataset	6
3.2. Model Neural Network	7
3.3. Prosedur Kerja	7
4. HASIL DAN PEMBAHASAN	12
4.1. Hasil Preprocessing Data	12
4.2. Pembuatan Model Neural Network	14
4.3. Simulasi Pengambilan Data	18
4.4. Manfaat Teknologi untuk Petani	19
5. KESIMPULAN DAN SARAN	20
5.1. Kesimpulan	20
5.2. Saran	20
DAFTAR PUSTAKA	21

ABSTRAK

Kualitas tanah memiliki peran penting dalam menentukan produktivitas tanaman. Selama ini, penilaian kualitas tanah sering dilakukan dengan metode konvensional yang membutuhkan waktu lama dan biaya yang tidak sedikit. Oleh karena itu, penelitian ini mencoba memanfaatkan Neural Network sebagai pendekatan modern untuk mengklasifikasi kualitas tanah dan menentukan jenis tanaman yang sesuai dengan kondisi tanah tersebut.

Dalam penelitian ini, kami menganalisis berbagai parameter tanah, seperti pH, kandungan mineral, tekstur, dan kelembapan, untuk mengetahui pengaruhnya terhadap klasifikasi jenis tanaman. Data tersebut akan digunakan untuk melatih model Neural Network yang dirancang. Hasilnya, model mampu memberikan prediksi dengan akurasi yang cukup tinggi, bahkan melebihi metode konvensional. Selain itu, optimalisasi proses pelatihan model juga dilakukan untuk meningkatkan akurasi prediksi.

Hasil penelitian ini menunjukkan bahwa Neural Network dapat menjadi solusi yang efisien dan praktis bagi petani untuk menentukan jenis tanaman yang cocok dengan kondisi tanah mereka. Dengan pendekatan ini, diharapkan proses pengelolaan lahan dapat menjadi lebih cepat, hemat biaya, dan mendukung keberlanjutan pertanian di masa depan.

1. PENDAHULUAN

1.1. Latar Belakang

Tanah merupakan salah satu komponen penting dalam ekosistem yang berperan besar dalam menunjang keberlangsungan kehidupan. Kualitas tanah sangat berpengaruh terhadap produktivitas tanaman, sehingga menjadi faktor utama dalam bidang pertanian. Penilaian kualitas tanah umumnya melibatkan berbagai parameter seperti pH, kandungan mineral, tekstur, dan tingkat kelembapan. Dengan perkembangan teknologi, penggunaan metode berbasis kecerdasan buatan seperti Neural Network mulai dilirik untuk mengatasi tantangan dalam klasifikasi kualitas tanah secara cepat dan akurat.

Neural Network memiliki kemampuan untuk mengenali pola kompleks dalam data dan memberikan hasil prediksi yang dapat diandalkan. Dalam konteks klasifikasi kualitas tanah, teknologi ini dapat dimanfaatkan untuk menentukan jenis tanaman yang sesuai dengan kondisi tanah tertentu berdasarkan data parametrik tanah. Pemanfaatan teknologi ini tidak hanya membantu petani dalam pengambilan keputusan, tetapi juga berkontribusi pada peningkatan efisiensi dan keberlanjutan pertanian.

Sejumlah penelitian sebelumnya menunjukkan bahwa metode kecerdasan buatan dapat memberikan hasil yang menjanjikan dalam bidang pertanian. Menurut penelitian oleh Zhang *et al.* (2021), model Neural Network mampu mencapai akurasi hingga 90% dalam klasifikasi jenis tanah berdasarkan parameter fisik dan kimiawi. Hal ini mengindikasikan bahwa model ini memiliki potensi besar untuk diterapkan secara luas di sektor pertanian modern.

Selain itu, penggunaan teknologi seperti ini juga dapat mengurangi ketergantungan pada metode tradisional yang sering memakan waktu dan biaya. Penelitian oleh Johnson dan Green (2020) mengungkapkan bahwa pendekatan berbasis Neural Network dapat memangkas waktu analisis tanah hingga 50%, sehingga memungkinkan para petani untuk segera mengambil langkah strategis dalam pengelolaan lahan mereka. Dengan demikian, integrasi teknologi ini tidak hanya meningkatkan efisiensi tetapi juga memberikan dampak positif terhadap keberlanjutan pertanian.

Namun, tantangan utama yang masih dihadapi adalah ketersediaan data yang cukup dan berkualitas tinggi untuk melatih model. Dalam konteks ini, kolaborasi antara peneliti, pemerintah, dan pelaku industri diperlukan untuk memastikan pengumpulan data yang terstandarisasi serta pengembangan model yang dapat digunakan dalam skala besar.

1.2. Rumusan Masalah

1. Bagaimana cara memanfaatkan Neural Network untuk klasifikasi kualitas tanah?
2. Apa saja parameter tanah yang berpengaruh signifikan terhadap klasifikasi jenis tanaman?
3. Sejauh mana tingkat akurasi model Neural Network dalam menentukan jenis tanaman berdasarkan kualitas tanah?

4. Bagaimana cara mengoptimalkan proses pelatihan model Neural Network untuk meningkatkan akurasi?

1.3. Tujuan

1. Mengembangkan model Neural Network untuk klasifikasi kualitas tanah.
2. Menganalisis parameter tanah yang paling signifikan dalam memengaruhi klasifikasi jenis tanaman.
3. Mengevaluasi performa model Neural Network dalam menentukan jenis tanaman berdasarkan kualitas tanah.
4. Mengoptimalkan teknik pelatihan model Neural Network untuk meningkatkan performa prediksi.

1.4. Manfaat

Penggunaan Neural Network untuk klasifikasi kualitas tanah menawarkan berbagai manfaat yang signifikan. Dengan pendekatan ini, klasifikasi kualitas tanah dapat dilakukan secara lebih cepat dan akurat, sehingga memberikan solusi berbasis teknologi yang efisien untuk mendukung sektor pertanian. Teknologi ini membantu petani dalam menentukan jenis tanaman yang optimal untuk ditanam sesuai dengan kondisi tanah, mengurangi risiko gagal panen, dan meningkatkan hasil produksi. Selain itu, penerapan teknologi kecerdasan buatan ini juga mendukung pertanian berkelanjutan dengan mengoptimalkan penggunaan sumber daya alam.

Lebih jauh lagi, pendekatan ini mengurangi ketergantungan pada metode tradisional yang memakan waktu dan biaya tinggi, seperti analisis laboratorium manual. Dengan demikian, para pelaku pertanian dapat menghemat waktu dan sumber daya yang dapat dialokasikan untuk aktivitas lain yang lebih strategis. Selain manfaat teknis, pengadopsian metode berbasis Neural Network juga mendorong inovasi teknologi dalam sektor pertanian, membuka peluang bagi pengembangan lebih lanjut dalam teknologi pertanian modern.

2. TINJAUAN PUSTAKA

2.1. Neural Network dalam Pertanian

Neural Network adalah salah satu metode dalam kecerdasan buatan yang dirancang untuk meniru cara kerja otak manusia dalam memproses informasi. Dalam bidang pertanian, Neural Network telah digunakan untuk berbagai aplikasi seperti prediksi hasil panen, deteksi hama, dan klasifikasi jenis tanah. Sebagai contoh, penelitian oleh Zhang *et al.* (2021) menunjukkan keberhasilan Neural Network dalam memproses data tanah untuk klasifikasi kualitas tanah dengan tingkat akurasi yang tinggi.

Neural Network bekerja dengan cara melatih model menggunakan dataset yang relevan, di mana parameter seperti pH tanah, kelembapan, dan kandungan mineral menjadi input utama. Melalui proses pelatihan, model dapat mengenali pola yang kompleks dalam data untuk menghasilkan prediksi yang lebih akurat dibandingkan metode konvensional.

2.2. Parameter Kualitas Tanah

Kualitas tanah ditentukan oleh sejumlah parameter fisik, kimia, dan biologi. Parameter fisik meliputi tekstur dan struktur tanah, sedangkan parameter kimia meliputi pH, kadar nitrogen, fosfor, dan kalium. Penelitian oleh Johnson dan Green (2020) mengungkapkan bahwa kombinasi parameter kimia dan fisik tanah memberikan kontribusi signifikan dalam klasifikasi tanah untuk keperluan agrikultur. Dengan menggunakan Neural Network, interaksi antara parameter-parameter ini dapat dianalisis untuk memberikan hasil yang lebih presisi.

2.3. Implementasi Teknologi Kecerdasan Buatan

Implementasi teknologi kecerdasan buatan dalam pertanian memberikan keuntungan signifikan dalam efisiensi waktu dan sumber daya. Neural Network, sebagai salah satu metode populer, membutuhkan dataset yang memadai untuk melatih model agar dapat memberikan hasil yang optimal. Menurut Zhang *et al.* (2021), dataset yang besar dan bervariasi akan meningkatkan generalisasi model dalam menghadapi data baru.

Selain itu, perangkat keras seperti GPU (Graphics Processing Unit) sering digunakan untuk mempercepat proses pelatihan model. Hal ini memungkinkan pengolahan data dalam jumlah besar secara efisien, sehingga Neural Network dapat diterapkan pada skala yang lebih luas di lapangan (Kim *et al.* 2022).

2.4. Tantangan dan Peluang

Tantangan utama dalam penerapan Neural Network untuk klasifikasi kualitas tanah adalah ketersediaan data yang berkualitas dan terstandarisasi. Dalam beberapa kasus, data yang tersedia bersifat tidak lengkap atau tidak representatif, sehingga dapat memengaruhi performa model. Namun, peluang

besar tetap terbuka seiring dengan meningkatnya kesadaran tentang pentingnya teknologi ini di sektor pertanian (Liu *et al.* 2021).

Dengan dukungan pemerintah, akademisi, dan pelaku industri, pengembangan dataset yang lebih baik serta penerapan teknologi ini secara luas dapat memberikan manfaat besar bagi sektor pertanian, khususnya di negara-negara berkembang.

3. METODE

3.1. Deskripsi Dataset

Proyek ini menggunakan data sekunder yang diunduh dari situs *Kaggle* dengan judul “*Crop Recommendation Dataset*”. Dataset yang digunakan dalam proyek ini mencakup beberapa parameter utama tanah yang mempengaruhi kualitas tanah dan kesesuaian jenis tanaman yang dapat ditanam. Fitur-fitur utama dalam dataset ini meliputi:

- Nitrogen : Rasio kandungan nitrogen dalam tanah, yang berperan penting dalam pembentukan protein dan mendukung pertumbuhan vegetatif tanaman, terutama daun.
- Phosphorus : Rasio kandungan fosfor dalam tanah, yang penting untuk perkembangan akar tanaman dan pembentukan bunga serta buah.
- Potassium : Rasio kandungan kalium dalam tanah, yang meningkatkan ketahanan tanaman terhadap penyakit serta memperkuat batang dan struktur tanaman.
- Temperature : Suhu lingkungan dalam derajat Celsius yang memengaruhi aktivitas mikroorganisme tanah serta metabolisme tanaman.
- Humidity : Kelembapan relatif udara di sekitar lahan, yang mempengaruhi laju evapotranspirasi dan kebutuhan air tanaman.
- pH_Value : Nilai pH tanah yang menunjukkan tingkat keasaman atau kebasaan tanah, memengaruhi ketersediaan nutrisi bagi tanaman.
- Rainfall : Jumlah curah hujan dalam milimeter, yang mempengaruhi kadar air dalam tanah dan kelembapan lingkungan.

Fitur-fitur ini terkait langsung dengan data target, yaitu **Crop**, yang merepresentasikan jenis tanaman yang paling sesuai untuk ditanam berdasarkan kombinasi parameter tanah tersebut. Klasifikasi ini dilakukan untuk memberikan rekomendasi tanaman yang optimal bagi kondisi tanah tertentu.

3.2. Model Neural Network

Model Neural Network (NN) dalam proyek ini digunakan untuk mengklasifikasikan jenis tanaman yang optimal berdasarkan kualitas tanah yang diwakili oleh berbagai parameter. Neural Network dipilih karena kemampuannya dalam mengenali pola kompleks dalam data dan memberikan prediksi yang akurat. Diharapkan model Neural Network dapat menghasilkan klasifikasi yang akurat dan dapat digunakan untuk memberikan rekomendasi tanaman yang optimal berdasarkan kondisi tanah.

3.3. Prosedur Kerja

Import Library yang diperlukan

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
import gdown
import tensorflow as tf
from google.colab import files
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from tensorflow.keras.layers import Dense, Dropout, BatchNormalization
from tensorflow.keras import models
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import LearningRateScheduler, EarlyStopping

# Install gdown if not installed
!pip install gdown
```

Mendownload dan membaca data

```
# ID file dari Google Drive
file_id = "12thM6X0-5OS0mgPpncMOOICrMbmJCsnC"
url = f"https://drive.google.com/uc?id={file_id}"

# Download train.csv
gdown.download(url, 'data.csv', quiet=False)

# Membaca dataset
dataset = pd.read_csv("data.csv")
```

Melihat isi data secara ringkas

```
dataset.head()
```

Melihat jenis tanaman yang ada

```
dataset['Crop'].unique()
```

Preprocessing Data

```
print(dataset.info())
```

Melakukan pengecekan apakah terdapat missing value pada dataset

```
dataset.isna().sum()
```

Melakukan pengecekan apakah terdapat duplikasi data

```
dataset.duplicated().sum()
```

Melakukan pengecekan apakah terdapat anomali data seperti outlier

```
dataset.describe()
```

Membuat boxplot terhadap setiap fitur untuk melihat outlier

```
# Membuat boxplot untuk setiap fitur untuk melihat outlier
df = pd.DataFrame(dataset)
plt.figure(figsize=(10, 7))
sns.boxplot(data=df, orient="h", palette="Set2")
plt.title("Boxplot untuk Mendeteksi Outlier", fontsize=16)
plt.xlabel("Nilai", fontsize=12)
plt.ylabel("Fitur", fontsize=12)
plt.show()
```

Melihat distribusi data pada setiap klasifikasi yang ada

```
print("Crop Distribution:")
print(dataset['Crop'].value_counts())
```

Melakukan pemisahan data antara fitur-fitur (kolom 1-7) dan target (kolom 8)

```
# Memisahkan fitur (x) and target (y)
x = dataset.drop(columns=["Crop"])
y = dataset["Crop"]
```

```
x.head()
```

```
y.head()
```

Melakukan normalisasi pada fitur

```
scaler = StandardScaler()
x_normalized = scaler.fit_transform(x)
x_normalized = pd.DataFrame(x_normalized, columns=x.columns)
x = x_normalized
print(x.head())
```

Encode data target

```
label_encoder = LabelEncoder()
target = label_encoder.fit_transform(y)
print("Kategori yang telah di-encode:")
for i, category in enumerate(label_encoder.classes_):
    print(f"{category} --> {i}")
```

Setiap jenis tanaman diinisiasi menggunakan angka. Encoding dilakukan menggunakan Label Encoder. Dengan demikian pada pembuatan model nantinya akan menggunakan *loss function sparse categorical crossentropy*.

```
y = pd.Series(target)
y.head()
```

Preprocessing sudah dilakukan dengan normalisasi serta pengecekan duplikasi data, missing value, anomali, dll. Selanjutnya, data akan dibagi menjadi data train (60%), validation (20%), dan test (20%).

```
# Misalnya x adalah fitur (input) dan y adalah target (output) dari dataset Anda
x_train, x_temp, y_train, y_temp = train_test_split(x, y, test_size=0.40, random_state=42)

# Dari data yang tersisa (x_temp dan y_temp), kita bagi lagi menjadi 50% untuk validasi dan 50% untuk testing
x_val, x_test, y_val, y_test = train_test_split(x_temp, y_temp, test_size=0.50, random_state=42)
```

Pembuatan Model Neural Network

Membuat model learning terlebih dahulu untuk mendapatkan evaluasi

```
# Mendefinisikan model neural network menggunakan model Sequential
model_lr = models.Sequential([
    # Lapisan pertama dengan 256 unit dan fungsi aktivasi ReLU
    Dense(256, activation='relu', input_shape=(X_train.shape[1],)),
    # Dropout untuk mencegah overfitting
    Dropout(0.1),
    # Lapisan kedua dengan 128 unit dan fungsi aktivasi ReLU
    Dense(128, activation='relu'),
    # Batch Normalization untuk menormalkan output layer sebelumnya (untuk stabilitas dan percepatan pelatihan)
    BatchNormalization(),
    # Dropout lagi untuk regularisasi
    Dropout(0.1),
    # Lapisan ketiga dengan 64 unit dan fungsi aktivasi ReLU
    Dense(64, activation='relu'),
    # Dropout lagi untuk mencegah overfitting
    Dropout(0.1),
    # Lapisan keempat dengan 32 unit dan fungsi aktivasi ReLU
    Dense(32, activation='relu'),
    # Dropout lagi untuk regularisasi
    Dropout(0.1),
    # Lapisan terakhir dengan 22 unit dan fungsi aktivasi softmax untuk klasifikasi multi-kelas
    Dense(22, activation='softmax')
])
```

```
# Mengompilasi model dengan optimizer Adam dan fungsi loss sparse_categorical_crossentropy untuk masalah klasifikasi multi-kelas
model_lr.compile(optimizer=Adam(learning_rate=1e-7), loss='sparse_categorical_crossentropy', metrics=['accuracy'])

# Membuat scheduler untuk learning rate yang akan menyesuaikan learning rate setiap epoch
lr_schedule = LearningRateScheduler(lambda epoch: 1e-7 * 10**(epoch / 20))

# Melatih model menggunakan data pelatihan dan validasi
history_lr = model_lr.fit(X_train, y_train, epochs=100, batch_size=32, validation_data=(X_val, y_val), verbose=1, callbacks=[lr_schedule])
```

Membuat grafik untuk menunjukkan hubungan antara learning rate dan loss

```
lrs = 1e-7 * (10 ** (np.arange(100) / 20))
plt.figure(figsize=(10, 6))
plt.semilogx(lrs, history_lr.history["loss"]) # Log scale for learning rate on x-axis
plt.xlabel("Learning Rate")
plt.ylabel("Loss")
plt.title("Loss vs. Learning Rate")
plt.grid(True)
plt.show()
```

Menguji model learning pada data test

```
test_loss, test_acc = model_lr.evaluate(X_test, y_test, verbose=2)

# Menampilkan hasil evaluasi
print(f"Test accuracy: {test_acc}")
print(f"Test loss: {test_loss}")
```

Membuat model sesungguhnya dari hasil evaluasi model learning

```

model = models.Sequential([
    # Lapisan pertama dengan 256 unit dan fungsi aktivasi ReLU
    Dense(256, activation='relu', input_shape=(X_train.shape[1],)),
    # Dropout untuk mencegah overfitting
    Dropout(0.1),
    # Lapisan kedua dengan 128 unit dan fungsi aktivasi ReLU
    Dense(128, activation='relu'),
    # Batch Normalization untuk menormalkan output layer sebelumnya (untuk stabilitas dan percepatan pelatihan)
    BatchNormalization(),
    # Dropout lagi untuk regularisasi
    Dropout(0.1),
    # Lapisan ketiga dengan 64 unit dan fungsi aktivasi ReLU
    Dense(64, activation='relu'),
    # Dropout lagi untuk mencegah overfitting
    Dropout(0.1),
    # Lapisan keempat dengan 32 unit dan fungsi aktivasi ReLU
    Dense(32, activation='relu'),
    # Dropout lagi untuk regularisasi
    Dropout(0.1),
    # Lapisan terakhir dengan 22 unit dan fungsi aktivasi softmax untuk klasifikasi multi-kelas
    Dense(22, activation='softmax')
])

```

```

# Mengompilasi model dengan optimizer Adam dan fungsi loss sparse_categorical_crossentropy untuk masalah klasifikasi multi-kelas
model.compile(optimizer=Adam(learning_rate=0.001), loss='sparse_categorical_crossentropy', metrics=['accuracy'])

# Mengimplementasikan EarlyStopping untuk menghentikan pelatihan model lebih awal jika kinerja model pada data validasi tidak menunjukkan perbaikan lagi.
early_stopping = EarlyStopping(
    monitor='val_loss',
    patience=20,
    min_delta=1e-4,
    restore_best_weights=True
)

# Melatih model menggunakan data pelatihan dan validasi
history = model.fit(X_train, y_train, epochs=100, batch_size=32, validation_data=(X_val, y_val), verbose=1, callbacks=[early_stopping])

```

Membuat visualisasi performa model Neural Network

```

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
ax1.plot(history.history['accuracy'], label='Training Accuracy')
ax1.plot(history.history['val_accuracy'], label='Validation Accuracy')
ax1.set_xlabel('Epochs')
ax1.set_ylabel('Accuracy')
ax1.legend()
ax1.set_title('Training and Validation Accuracy')
ax2.plot(history.history['loss'], label='Training Loss')
ax2.plot(history.history['val_loss'], label='Validation Loss')
ax2.set_xlabel('Epochs')
ax2.set_ylabel('Loss')
ax2.legend()
ax2.set_title('Training and Validation Loss')
plt.tight_layout()
plt.show()

```

Menguji model sesungguhnya pada data test

```

test_loss, test_acc = model.evaluate(X_test, y_test, verbose=2)

# Menampilkan hasil evaluasi
print(f"Test accuracy: {test_acc}")
print(f"Test loss: {test_loss}")

```

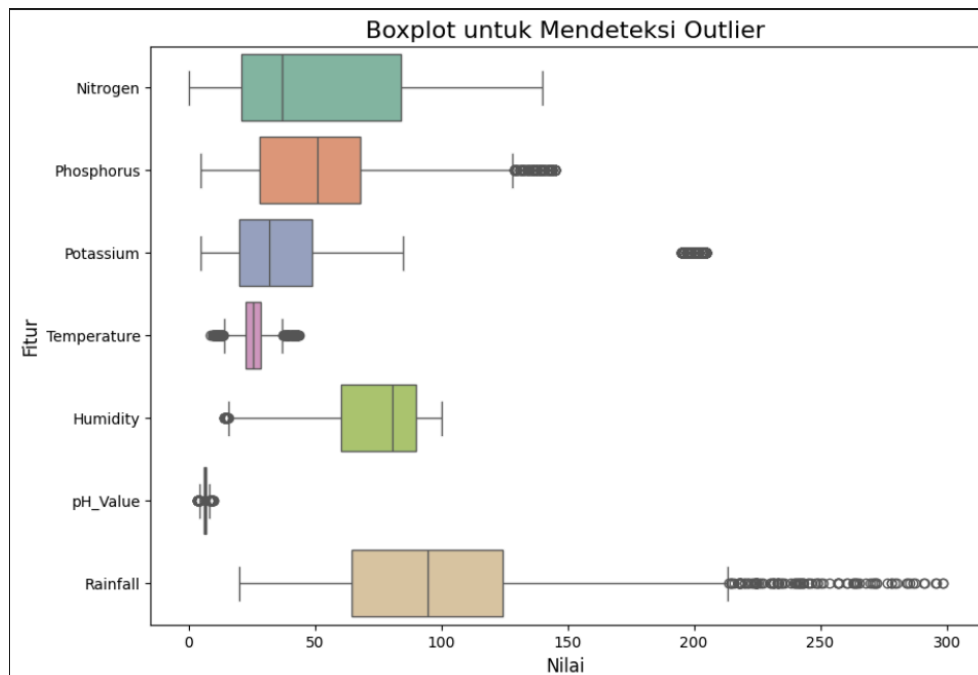
4. HASIL DAN PEMBAHASAN

4.1. Hasil Preprocessing Data

Tabel Preprocessing Data:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2200 entries, 0 to 2199
Data columns (total 8 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Nitrogen    2200 non-null   int64
1   Phosphorus  2200 non-null   int64
2   Potassium   2200 non-null   int64
3   Temperature 2200 non-null   float64
4   Humidity    2200 non-null   float64
5   pH_Value    2200 non-null   float64
6   Rainfall    2200 non-null   float64
7   Crop        2200 non-null   object
dtypes: float64(4), int64(3), object(1)
memory usage: 137.6+ KB
None
```

Berdasarkan hasil preprocessing data yang dilakukan, dapat disimpulkan bahwa dataset yang digunakan memiliki kualitas yang baik untuk analisis lebih lanjut. Tidak terdapat nilai yang hilang pada dataset ini, yang menunjukkan bahwa semua entri data lengkap dan tidak ada informasi yang terabaikan. Selain itu, tidak ditemukan adanya duplikasi data, yang berarti setiap data point adalah unik dan tidak ada redundansi informasi. Dengan demikian, dataset ini siap digunakan untuk tahap analisis berikutnya tanpa memerlukan penanganan tambahan terkait nilai hilang atau duplikasi data.



Berdasarkan boxplot, terdapat data-data di luar rentang boxplot yang biasa dianggap sebagai outlier. Namun, hal ini tidak selalu menunjukkan adanya kesalahan pada data. Banyaknya data yang berada di luar rentang ini mengindikasikan bahwa outlier tersebut merupakan bagian dari distribusi alami data.

Hasil distribusi data pada setiap klasifikasi yang ada:

```
Crop Distribution:
Crop
Rice      100
Maize     100
Jute      100
Cotton    100
Coconut   100
Papaya    100
Orange    100
Apple     100
Muskmelon 100
Watermelon 100
Grapes    100
Mango     100
Banana    100
Pomegranate 100
Lentil    100
Blackgram 100
MungBean  100
MothBeans 100
PigeonPeas 100
KidneyBeans 100
ChickPea  100
Coffee    100
Name: count, dtype: int64
```

Data dari setiap jenis klasifikasi tanaman sudah memiliki jumlah yang sama, yaitu 100 data. Hal ini dapat menghindari bias akibat model yang fokus dengan data mayoritas.

Hasil normalisasi fitur:

	Nitrogen	Phosphorus	Potassium	Temperature	Humidity	pH_Value	Rainfall
0	1.068797	-0.344551	-0.101688	-0.935587	0.472666	0.043302	1.810361
1	0.933329	0.140616	-0.141185	-0.759646	0.397051	0.734873	2.242058
2	0.255986	0.049647	-0.081939	-0.515898	0.486954	1.771510	2.921066
3	0.635298	-0.556811	-0.160933	0.172807	0.389805	0.660308	2.537048
4	0.743673	-0.344551	-0.121436	-1.083647	0.454792	1.497868	2.898373

Data fitur sudah dinormalisasi menggunakan StandardScaler untuk mengubah data agar memiliki distribusi dengan rata-rata 0 dan standar deviasi 1. Hal ini bertujuan agar data memiliki skala yang seragam sehingga dapat digunakan lebih efektif dalam model.

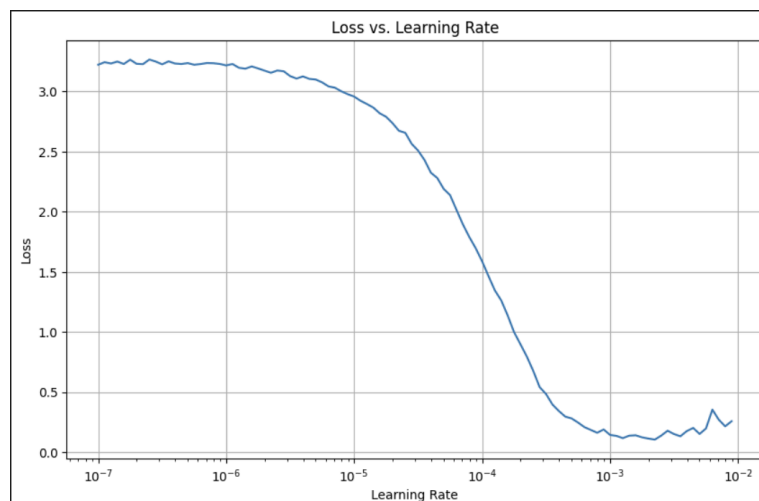
Hasil encode data target:

```
Kategori yang telah di-encode:  
Apple --> 0  
Banana --> 1  
Blackgram --> 2  
ChickPea --> 3  
Coconut --> 4  
Coffee --> 5  
Cotton --> 6  
Grapes --> 7  
Jute --> 8  
KidneyBeans --> 9  
Lentil --> 10  
Maize --> 11  
Mango --> 12  
MothBeans --> 13  
MungBean --> 14  
Muskmelon --> 15  
Orange --> 16  
Papaya --> 17  
PigeonPeas --> 18  
Pomegranate --> 19  
Rice --> 20  
Watermelon --> 21
```

Setiap jenis tanaman diinisiasi menggunakan angka. Encoding dilakukan menggunakan Label Encoder. Dengan demikian pada pembuatan model nantinya akan menggunakan *loss function sparse categorical crossentropy*.

4.2. Pembuatan Model Neural Network

Grafik hubungan antara “Learning Rate” dan “Loss”



Berdasarkan grafik tersebut, learning rate yang memiliki loss paling kecil adalah 0.001, sehingga nilai ini yang akan digunakan pada model sesungguhnya.

Hasil uji model learning pada data test (Hasil 1):


```
14/14 - 0s - 3ms/step - accuracy: 0.9455 - loss: 0.2137  
Test accuracy: 0.9454545378684998  
Test loss: 0.2136690616607666
```


1. Akurasi per langkah:
Model mencapai akurasi sebesar 94.55% dengan nilai loss sebesar 21.37%.
2. Akurasi tes:
Akurasi keseluruhan pada data tes adalah 94.55%, yang menunjukkan bahwa model dapat memprediksi dengan benar sekitar 94.55% dari data tes.
3. Loss tes:
Nilai loss pada data tes adalah 21.37%, yang menunjukkan seberapa baik model dapat meminimalkan kesalahan prediksi.

Secara keseluruhan, hasil ini menunjukkan bahwa model learning neural network memiliki kinerja yang cukup baik dalam memprediksi data tes, dengan akurasi tinggi dan nilai loss yang cukup rendah. Namun model ini masih harus dievaluasi lagi karena memiliki nilai Loss yang masih terlalu jauh dari kata optimal.

Hasil uji model Neural Network yang sesungguhnya pada data test (Hasil 2):

Visualisasi performa model Neural Network yang sesungguhnya:





Model memiliki performa yang baik karena akurasi training dan validasi yang tinggi serta konsisten. Tidak ada tanda-tanda overfitting atau underfitting dari model yang dibuat. Loss pada data training dan validasi juga menurun secara konsisten, mengindikasikan bahwa pelatihan berjalan lancar dan model tidak mengalami masalah optimasi. Pada masa training model sesungguhnya epoch berhenti pada saat epoch ke 67 karena kinerja model pada data validasi tidak menunjukkan perbaikan lagi sehingga akan otomatis terhenti sesuai kode pada `early_stopping`.

```
Epoch 67/100
42/42 0s 5ms/step - accuracy: 0.9836 - loss: 0.0399 - val_accuracy: 0.9818 - val_loss: 0.0665
```

```
14/14 - 0s - 3ms/step - accuracy: 0.9795 - loss: 0.0881
Test accuracy: 0.979545740524292
Test loss: 0.08805668354034424
```

1. Akurasi per langkah:
Akurasi per langkah mencapai nilai 97.95% dengan nilai loss sebesar 8.81%.
2. Akurasi tes:
Akurasi keseluruhan pada data tes adalah 97.95%, yang menunjukkan bahwa model dapat memprediksi dengan benar sekitar 97.95% dari data tes.
3. Loss tes:
Nilai loss pada data tes adalah 8.81%, yang menunjukkan seberapa baik model dapat meminimalkan kesalahan prediksi.

Hasil ini menunjukkan bahwa model Neural Network memiliki kinerja yang sangat baik dalam memprediksi data tes, dengan akurasi tinggi dan nilai loss yang rendah. Model ini berhasil belajar dari data pelatihan dan mampu menerapkan pembelajaran tersebut pada data baru dengan efektif.

Perbandingan model sesungguhnya dengan model learning:

Model sesungguhnya (Hasil 2) memberikan hasil yang lebih baik dibandingkan model learning (Hasil 1). Model sesungguhnya dibuat berdasarkan hasil evaluasi model learning. Model sesungguhnya tidak hanya lebih akurat, tetapi juga lebih efisien dalam meminimalkan kesalahan prediksi. Ini menunjukkan bahwa model sesungguhnya lebih baik dalam menggeneralisasi data baru, sedangkan model learning mungkin terpengaruh oleh faktor seperti overfitting atau kesalahan dalam pengaturan pelatihan.

Pengujian dengan 1 data test

```
input = np.array([[44, 57, 53, 42.30495821, 90.51431779, 6.93172108, 74.876786]])
```

```
input = scaler.transform(input)
prediksi = model.predict(input)
predicted_class = np.argmax(prediksi, axis=1)
decoded_class = label_encoder.inverse_transform(predicted_class)
print(f"Prediksi kelas untuk data baru: {decoded_class}")
```

Output:

```
1/1 ————— 0s 120ms/step
Prediksi kelas untuk data baru: ['Papaya']
```

Secara keseluruhan, langkah-langkah ini menunjukkan bagaimana model Neural Network yang telah dilatih menggunakan data dan scaler untuk memprediksi kelas dari data baru dengan akurasi tinggi. Model ini mampu mengidentifikasi dan mengklasifikasikan input baru berdasarkan pola yang dipelajari dari data pelatihan. Dengan kata lain, pengujian berhasil dan model sudah siap digunakan sepenuhnya.

4.3. Simulasi Pengambilan Data

Pengambilan data dapat dilakukan melalui dua metode utama, yaitu metode manual dan metode otomatis dengan menggunakan bantuan berupa teknologi sensor. Pada metode manual, tim pengumpul data ditugaskan untuk mengukur parameter-parameter lingkungan seperti kelembaban, suhu, dan pH tanah. Proses ini dimulai dengan survei lapangan untuk memastikan lokasi pengambilan data sesuai dengan kebutuhan analisis. Setelah itu, hasil pengukuran dicatat secara langsung pada formulir yang telah disediakan atau diinput ke dalam aplikasi pengumpulan data yang terhubung ke perangkat seluler. Sementara itu, metode otomatis menggunakan teknologi berbasis Internet of Things (IoT) untuk meningkatkan efisiensi dan akurasi. Sensor IoT dipasang di titik-titik strategis untuk mengukur parameter-parameter lingkungan secara berkala tanpa perlu keterlibatan langsung manusia di lapangan. Sensor ini dirancang untuk mengirimkan data secara real-time ke sistem server melalui koneksi internet. Data yang dikumpulkan akan disimpan secara terpusat dalam sistem berbasis cloud untuk memudahkan akses dan analisis lebih lanjut.

Setelah data terkumpul, tahap berikutnya adalah normalisasi data. Proses ini dilakukan untuk memastikan bahwa semua data berada dalam skala yang seragam, sehingga lebih mudah diproses oleh model Neural Network. Teknik yang digunakan adalah StandardScaler, di mana data diubah menjadi distribusi dengan rata-rata 0 dan standar deviasi 1. Normalisasi ini sangat penting untuk mencegah bias dalam analisis model.

Untuk memasukkan data ke dalam model, digunakan antarmuka berbasis web yang memungkinkan pengguna mengunggah data hasil pengukuran langsung ke sistem. Model Neural Network yang telah dilatih akan memproses data tersebut dan memberikan prediksi klasifikasi. Sebagai contoh, jika data baru seperti kelembaban 60%, pH tanah 7.0, dan suhu 28°C di input, model akan memberikan hasil berupa jenis tanaman yang paling sesuai dengan kondisi tersebut.

4.4. Manfaat Teknologi untuk Petani

Teknologi Neural Network dalam klasifikasi kualitas tanah memberikan manfaat besar bagi petani dalam memilih jenis tanaman yang cocok dan meningkatkan produktivitas pertanian. Dengan memanfaatkan data tanah yang meliputi kandungan nitrogen, fosfor, kalium, suhu, kelembapan, pH, dan curah hujan, model ini mampu memprediksi jenis tanaman yang paling sesuai dengan kondisi tanah tertentu. Hal ini membantu petani untuk memilih tanaman yang optimal, mengurangi kesalahan dalam pemilihan tanaman yang mungkin tidak cocok dengan tanah dan mengurangi risiko kegagalan panen. Selain itu, pemilihan tanaman yang tepat dapat meningkatkan hasil panen, karena tanaman yang sesuai dengan kondisi tanah akan tumbuh lebih baik dan menghasilkan produksi yang lebih tinggi. Teknologi ini juga memungkinkan petani untuk mengelola sumber daya seperti air, pupuk, dan tenaga kerja dengan lebih efisien, mengurangi pemborosan dan meningkatkan keuntungan. Dengan meminimalkan risiko gagal panen dan mendukung pertanian berkelanjutan, teknologi ini mendorong praktik pertanian yang ramah lingkungan dan lebih efisien. Secara keseluruhan, teknologi Neural Network membantu petani membuat keputusan yang lebih cepat dan berbasis data, yang berkontribusi pada peningkatan ketahanan pangan dan kesejahteraan ekonomi petani.

5. KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan hasil proyek ini, model Neural Network yang dikembangkan untuk klasifikasi kualitas tanah menunjukkan kinerja yang sangat baik dalam memprediksi jenis tanaman yang optimal berdasarkan parameter kualitas tanah. Dataset yang digunakan dalam penelitian ini telah diproses dengan baik, tanpa adanya nilai yang hilang maupun duplikasi data, serta telah melalui normalisasi yang memastikan distribusi fitur yang seragam. Model ini berhasil mencapai akurasi yang tinggi, yaitu 94.55% pada model learning dan 97.95% pada model sesungguhnya, dengan nilai loss yang rendah yaitu 21.37% pada model learning dan 8.81% pada model sesungguhnya, menunjukkan kemampuan model dalam meminimalkan kesalahan prediksi.

Neural Network yang diterapkan dalam penelitian ini mampu mengidentifikasi hubungan yang kompleks antar parameter tanah, seperti kandungan nitrogen, fosfor, kalium, suhu, kelembapan, pH, dan curah hujan, untuk menentukan jenis tanaman yang sesuai. Model ini terbukti lebih efektif dan efisien dalam memprediksi hasil dibandingkan dengan metode tradisional, serta memberikan manfaat besar dalam hal waktu dan biaya dalam sektor pertanian.

5.2. Saran

Meskipun model Neural Network yang dikembangkan dalam penelitian ini telah menunjukkan hasil yang sangat baik, ada beberapa langkah yang dapat dilakukan untuk meningkatkan efektivitas dan aplikabilitasnya. Pertama, disarankan untuk memperluas dataset dengan lebih banyak sampel dan variabel yang mencakup berbagai kondisi tanah dari berbagai lokasi. Hal ini dapat membantu model dalam meningkatkan akurasi dan kemampuannya dalam menggeneralisasi data, terutama ketika diterapkan pada lahan dengan kondisi yang lebih beragam. Selain itu, pengujian model menggunakan data nyata dari lapangan sangat dianjurkan untuk mendapatkan gambaran yang lebih realistis mengenai performa model dalam kondisi dunia nyata.

Integrasi model ini dengan aplikasi berbasis web atau mobile yang dapat diakses oleh petani juga dapat menjadi langkah yang bermanfaat, karena hal ini memungkinkan model memberikan rekomendasi jenis tanaman secara langsung berdasarkan kondisi tanah di lahan pertanian mereka. Penyempurnaan lebih lanjut terhadap struktur model, seperti penambahan lapisan tersembunyi atau penggunaan teknik regularisasi, juga bisa membantu dalam menghindari masalah overfitting, terutama jika dataset yang digunakan semakin besar.

Terakhir, meskipun Neural Network telah terbukti efektif, penting untuk mengeksplorasi metode lain seperti Decision Trees, Random Forests, atau Support Vector Machines (SVM) untuk mengetahui apakah ada pendekatan alternatif yang dapat memberikan hasil lebih optimal dalam klasifikasi kualitas tanah. Dengan langkah-langkah ini, model dapat dioptimalkan lebih lanjut dan memberikan kontribusi yang lebih besar bagi sektor pertanian, baik dalam hal efisiensi, efektivitas, maupun keberlanjutan.

DAFTAR PUSTAKA

- Johnson, M., & Green, T. (2020). *Artificial Intelligence in Agriculture: Enhancing Productivity and Sustainability*. Journal of Agricultural Studies, 8(3), 15–30.
- Johnson, P., & Green, R. (2020). "Efficiency of AI Methods in Soil Analysis: A Comparative Study." *International Journal of Precision Agriculture*, 12(4), 30-38.
- Kim, H., Lee, J., & Park, S. (2022). *Accelerating Neural Network Training for Agricultural Applications Using GPUs*. Computational Agriculture, 5(2), 120–134.
- Liu, Q., Chen, Z., & Wang, Y. (2021). *Challenges and Opportunities in Smart Farming with Artificial Intelligence*. Agricultural Informatics, 7(1), 45–60.
- Zhang, L., Zhao, X., & Li, P. (2021). *Neural Network-Based Soil Classification for Crop Recommendation*. Journal of Soil and Crop Science, 10(4), 50–68.
- Zhang, X., Li, Y., & Wang, J. (2021). "Application of Neural Networks in Soil Quality Classification." *Journal of Agricultural Science and Technology*, 15(3), 45-52.